

Diagnóstico de pareamento

- **O que diz:** há 141 pares no horizonte de 3 s e 144 pares em 5 s (pareamento 1-a-1 por hiperparâmetros). Isso bate com a remoção de algumas linhas e mostra que quase todo o planejamento ficou comparável nas duas direções.
Leitura: bom equilíbrio entre as planilhas e baixo “descasamento”; a base para comparar 11→12 vs 12→11 é sólida.

Resumo pareado por horizonte ($\Delta Z = Z_{(11 \rightarrow 12)} - Z_{(12 \rightarrow 11)}$)

- **3 s:** viés médio positivo ($\approx +0,34 \sigma$) e desvio-padrão $\sim 1,29 \sigma$.
- **5 s:** viés médio levemente negativo ($\approx -0,19 \sigma$) e desvio-padrão $\sim 1,35 \sigma$.
Leitura: há **bias de direção** (sinal muda com o horizonte) e **dispersão** considerável em ambos os casos — indício de sensibilidade ao domínio.

Scatter pareado (3 s e 5 s)

- **O que se vê:** nuvens com **dispersão visível** e pontos afastados da diagonal $y=x$ em ambos os horizontes. A faixa de valores em 3 s chega mais alta (até ~ 10 em Z) do que em 5 s (até $\sim 4-6$).
Leitura: **robustez moderada para baixa**; o ranking dos “melhores” muda conforme o domínio e o horizonte (coerente com Jaccard e Spearman abaixo).

Bland–Altman (3 s e 5 s)

- **O que se vê:** viés próximo de zero em média, porém **limites de concordância largos** (diferenças de Z com amplitude de várias sigmas). Sinais de **heterocedasticidade** (dispersão variando com a média).
Leitura: concordância **limitada** entre direções; mesmo quando a média é similar, a variação entre domínios é relevante.

Sobreposição de Top-k (Jaccard)

- **O que se vê:** índices Jaccard entre $\sim 0,05$ e $\sim 0,30$ nos vários k e horizontes.
Leitura: **baixa a moderada estabilidade** do conjunto dos “Top-k” entre domínios — os melhores no 11→12 nem sempre são os mesmos no 12→11 (sobretudo em k pequenos).

Concordância de ranking (Spearman-like)

- **O que se vê:** correlação de ranking **fraca-positiva** ($\sim 0,28-0,29$) ao longo de 3–5 s.
Leitura: os **ranks mudam** de uma direção para outra; existe alguma ordem comum, mas longe de forte.

Efeitos principais (OLS por direção) + consistência de sinais

- **Ajustes:** $R^2 \approx 0,30$ (11→12) e $0,13$ (12→11); explica-se mais variação no sentido 11→12 do que no 12→11.
- **Fatores com maior influência (módulo do coeficiente):** aparecem recorrentemente `resample_scaled`, `seconds`, `batch_log2`, a interação `resample_scaled:seconds`, além de `model_LSTM`, `units_avg`, `epochs` e `timesteps:units_avg` entre os top termos (ver barras).
- **Consistência de sinais:** a barra “Consistência de sinais” mostra mistura de “Igual/Flip”, i.e., alguns efeitos **trocaram sinal entre direções**, reforçando a natureza **cross-domain-sensitive** do problema.
Leitura: (i) **resample e seconds** (e sua interação) são críticos; (ii) **batch** maior tende a ajudar (coeficiente $|\beta|$ relevante para `batch_log2`); (iii) há **assimetria entre domínios**, com parte dos efeitos mudando sinal.

Top-N robustos (critério min-Z)

- **O que se vê:** no 3 s e 5 s predominam **GRU/LSTM com resample=100 ms, batch grande (≥ 1024)** e faixas de **units** médias/altas; as linhas listadas mostram pares com **bom desempenho simultâneo** nas duas direções.
Leitura: há **ilhas de robustez** — especialmente combinações com 100 ms e lote grande — úteis como baseline “cross-domain”.

Síntese (o que eu concluo)

1. **Robustez cross-domain limitada:** scatter, Bland–Altman, Jaccard e Spearman convergem para a mesma história: **os modelos respondem ao domínio** (trajeto/dia) — rankings e magnitudes mudam entre 11→12 e 12→11.
2. **Fatores mais alavancáveis:** `resample` e `seconds` (e sua interação) aparecem como **drivers principais**, seguidos de `batch`; `units` e `timesteps` também contam, sobretudo via interação. Isso dá **alavancas claras** para o próximo ciclo de otimização.
3. **Direções assimétricas:** o ajuste explica mais no 11→12 ($R^2 \sim 0,30$) do que no 12→11 ($R^2 \sim 0,13$), e há **inversões de sinal** em alguns efeitos — confirmar e discutir como “**domain shift**” no texto.
4. **Configurações-âncora:** as combinações 100 ms + **batch alto** (e faixas de units intermediárias/altas) se repetem entre os Top-N robustos — vale usá-las como **baseline estável** e ponto de partida para finos

ajustes por horizonte.

Se quiser, eu já formato um parágrafo “Resultados – Robustez cross-domain” para a dissertação (amarrando estes achados com linguagem acadêmica e referências), e uma tabela “Recomendações de tuning por horizonte” com base nos coeficientes OLS e nos Top-N.